

Un agente que vigila 192 modelos

Arquitectura cognitiva para monitoreo de modelos en producción

Taller 02 · II Programa de Especialización en IA Generativa y MLOps

Ernesto Anaya · 8 y 9 de agosto de 2026

Dónde estamos

Este es el **último curso** del programa. Ya recorrieron:

Módulo	Lo que trajeron
Fundamentos y MLOps	MLflow, DVC, detección de drift
Despliegue	FastAPI, Docker, GitHub Actions, Kubernetes
Generativa y agentes	LangChain, RAG, LangGraph, ReAct, Reflection
Taller 01	Auditoría de procesos y chatbot de cumplimiento

Hoy se junta todo: **un agente generativo vigilando modelos desplegados.**

Empecemos por el caso

No por el agente

Una cadena de retail

24 tiendas × 8 categorías = 192 modelos de pronóstico de demanda.

Cada madrugada un job los carga, proyecta **14 días**, y con eso se decide qué reponer en cada tienda.

```
dem-panaderia-callao      dem-lacteos-cusco  
dem-bebidas-arequipa     dem-carnes-iquitos  
...                       188 más
```

¿Qué es "un modelo en producción"?

No es un chatbot. Es un **artefacto entrenado** — un `.joblib` con pesos.

- 192 archivos en disco, cada uno con su versión y su fecha de entrenamiento
- **No hay un contenedor por modelo:** un solo job los carga a todos
- La relación modelo ↔ contenedor no es 1 a 1

En la flota conviven modelos de distinta edad. El registro lo dice:

`version: 2` en 168 de ellos, `version: 3` en los 24 que se reentrenaron ayer.

Los modelos funcionan

Hasta que dejan de funcionar. Y fallan de maneras distintas:

	Qué pasa
	Una categoría falla en las 24 tiendas a la vez
Sesgo silencioso	La demanda cae despacio en toda la cadena
	Una tienda deja de reportar
Quiebre de stock	La venta observada queda bajo la demanda real

Cada una exige una respuesta distinta. Y una de ellas exige **no hacer nada**.

Caso 1 · La campaña promocional

Un descuento más agresivo que cualquiera del entrenamiento.

bebidas	MAPE	12.9% → 30.2%	en las 24 tiendas
sesgo		-2.0% → -10.5%	sub-pronóstico

Sesgo **negativo**: el modelo pronostica de menos.

Menos stock del necesario → **quiebre** → **venta perdida**.

Esta se ve. El MAPE se dispara y cualquier tablero la muestra.

Caso 2 · El sesgo silencioso

La demanda cae despacio en toda la cadena. El modelo sigue igual.

Señal	Antes	Después	
MAPE de la flota	13.8%	14.5%	+5%
Modelos sobre el umbral de alerta	7 / 192	14 / 192	ruido

36,567

unidades de más en almacén, en catorce días

Ninguna alarma sonó.

MAPE y sesgo no dicen lo mismo

MAPE — cuánto se equivoca. Siempre positivo, siempre ruidoso.

Sesgo — hacia **qué lado** se equivoca.

- Sesgo positivo sostenido → sobre-pronóstico → **sobre-stock**
- Sesgo negativo sostenido → sub-pronóstico → **quiebre**

Y hay una asimetría que lo cambia todo:

En una flota sana el MAPE de una categoría sube hasta **+20%** solo por alejarse de su fecha de entrenamiento. El sesgo no se mueve **ni 1.1 puntos**.

Una señal ruidosa y una limpia. Solo una habla de plata.

¿Por qué no basta un tablero?

Hoy alguien abre un Excel los lunes y revisa las cinco categorías más grandes.

Los otros 152 modelos nadie los mira.

Y aunque los mirara: un umbral fijo sobre 192 modelos no distingue envejecimiento normal de un problema real. Marca 88 de 192 modelos sanos.

Lo que falta no es más datos. Es **criterio**, aplicado 192 veces cada mañana.

Reto 1

Encuentra el problema a mano

Herramientas de percepción

Un LLM no puede leer 17,472 filas de telemetría. Y aunque pudiera, no debe.

Una herramienta de percepción **agrega y devuelve una lectura**, no datos crudos.

```
@tool
def comparar_periodos(dias_recientes=14, dias_base=45,
                     dimension="categoria") -> dict:
    """Compara una ventana reciente contra una línea base
    y mide si la diferencia es real."""
```

Siete herramientas. Todas de lectura. Ninguna devuelve una fila.

Tres trampas, todas medidas

1 · El sesgo no se promedia

Promediar porcentajes está sesgado hacia arriba. Panadería marcaba **+9.2%** en un mundo intacto. Como cociente de totales: **+0.7%**.

2 · Medir lo normal con la ventana que auditas

Una tienda muda tres semanas tiene mediana cero en esas tres semanas. La avería pasa por normalidad.

3 · Significativo $\neq$ relevante

Con mil días-modelo, el test de Kolmogorov-Smirnov marca real cualquier cosa.

El umbral depende de por dónde cortes

Medido sobre la flota sana, donde nada está roto:

dimensión	modelos por grupo	máx Δ MAPE	máx Δ sesgo
categoría	24	+19.6%	1.05 pp
región	~40	+15.2%	2.31 pp

Un umbral único calibrado con categorías marca **tres tiendas sanas** como derivadas. El agente le cree — y hace bien: el error no es suyo.

Reto 2

Escribe la herramienta

Criterio: en la flota sana, cero banderas

Reto 3 · El primer agente

Un bucle ReAct pelado. Un LLM con herramientas, nada más.

```
LLM ⇌ herramientas
```

Funciona. Llama herramientas, encuentra cosas, suena convincente.

Córranlo tres veces sobre el mismo escenario y comparen.

Lo que le pasa a un bucle sin arquitectura

- Concluye con lo primero que encuentra, sin contrastar contra una línea base
- Ordena por la señal más ruidosa y se queda con los dos números más grandes
- Dramatiza el impacto con cifras que no significan lo que dice
- Mañana redescubre lo mismo y vuelve a alertar

Nada de esto se arregla con un prompt más largo.

¿Qué le falta?


Sesión 2

La arquitectura cognitiva

Domingo 9 de agosto

Seis capas, un trabajo cada una

percepcion → diagnostico → reflexion → recomendacion → accion



Capa	Su único trabajo
	Decide qué mirar. No concluye
Diagnóstico	Evidencia → hipótesis, con alcance y severidad
	Intenta refutarse
Revisión	Si la crítica se sostiene, reescribe
	Ejecuta lo que la política deja pasar

Más **memoria**, que atraviesa todas.

La forma del problema importa más que su tamaño

- Degradación en **una categoría** a lo largo de todas las tiendas
→ la causa es **del producto**
- En **una tienda** a lo largo de todas las categorías
→ la causa es **de esa tienda**
- En **todas**
→ la causa no es de ninguna: es **de la cadena**

Esto no es un truco de prompt. Es lo que un ingeniero de guardia razona, escrito donde el agente lo lea.

Memoria

Sin memoria, el agente redescubre el mismo problema cada mañana y emite la misma alerta.

Con memoria puede decir tres cosas que un tablero nunca dice:

| **esto ya lo reporté · esto empeoró desde ayer · esto es nuevo**

Lee su historial **antes** de diagnosticar. Lo escribe **después**.

Reflexión

Antes de alertar, el agente intenta refutarse. Esto lo escribió él, sobre su propio diagnóstico, en una corrida real:

"Un delta de MAPE de 19.6% sin bandera significa que el sistema ya evaluó eso y lo descartó. No puedo ignorarlo solo porque el número se ve grande."

"Inventé impacto de negocio. Dije '9,436 unidades de sobre-stock' pero eso es el error acumulado del pronóstico, no sobre-stock. **Estoy dramatizando.**"

Se acusa de dramatizar. Y se baja la severidad.

Pero objetar no alcanza

En el mundo del sesgo silencioso, el agente reportó `sin_hallazgos`.

Y acto seguido, en su propia crítica:

"Tengo banderas de sesgo encendidas en 8/8 categorías y 4/5 regiones.

Eso NO es ruido normal: es un patrón sistemático."

"Sí hay hallazgo: hay DERIVA."

Su recomendación también era correcta: reentrenar los 192 modelos.

Sabía la respuesta. El grafo no le dejaba decirla.

Una reflexión que no puede corregir
es decorativa

Revisión

El nodo que faltaba. Cuando la crítica sigue en pie y ya no quedan vueltas:

- Misma evidencia, sin llamar más herramientas
- Reescribir el diagnóstico haciéndose cargo de las objeciones
- Y **decirlo**: la salida marca "reescrito tras la reflexión"

Sin él, el titular sale contradiciendo a las recomendaciones impresas debajo.

Acción

Hasta aquí el agente recomienda. Ahora **ejecuta**: dispara el reentrenamiento de los modelos que él mismo señaló, y queda en bitácora.

```
✓ reentrenar → 24 modelos de panaderia      1.5s
✓ reentrenar → 24 modelos de lacteos         1.4s
```

Y con eso cambia la naturaleza del riesgo.

Equivocarse deja de costar una alerta

y pasa a costar 24 modelos entrenados con datos malos

El freno va en código

El permiso para actuar **no se le pregunta al modelo de lenguaje**.

```
# Si el diagnóstico es una anomalía, el problema está en los datos:  
# reentrenar contra un feed roto enseña ruido.  
es_anomalia = hipotesis.get("tipo") == "anomalia"
```

Dos reglas hacen el trabajo pesado:

- **Naturaleza del problema** — con anomalía, nunca se reentrena
- **Radio de daño** — una categoría son 24 modelos y se deshace entrenando otra vez; la flota son 192 y no queda ninguno sano con qué comparar

Un prompt no puede persuadir a un `if`.

La trampa

Escenario `feed_caído` . Una tienda deja de reportar: sus filas **no llegan en cero, no llegan.**

MAPE de la flota	13.73%	← impecable
Sesgo	+0.66%	← impecable
Banderas de deriva	ninguna	← impecable
Anomalías	1	← arequipa, 21 días sin telemetría

Si el agente solo mira drift, no ve nada y se va tranquilo a su casa.

Si recomienda reentrenar, **entrena con datos fantasma.**

Lo que hizo el agente

```
tipo: anomalia · alcance: tienda:arequipa · severidad: media
```

```
[inmediata] revisar_datos → Restaurar feed de Arequipa
```

```
"Sin datos de entrada, los 8 modelos de Arequipa no pueden  
evaluar demanda real ni reentrenarse."
```

```
ACCIÓN
```

```
x no se ejecutó: no es una acción automatizable
```

No cayó en la trampa. Y aunque hubiera caído, la política lo frenaba.

Ocho errores construyendo esto

Ninguno estaba en el modelo

Dónde estaban de verdad

Dos de cableado del grafo

El contexto no llegaba a la API. El estado no se propagaba entre nodos.

Uno de un simulador que no podía fallar

Devolvía un texto fijo, nunca llamaba una herramienta. No verificaba nada.

Cuatro de estadística bien calculada y mal planteada

Promediar porcentajes. Medir lo normal con la ventana auditada. Confundir significancia con relevancia. Ordenar los hallazgos por la métrica ruidosa.

Uno de un campo sin definir

`cobertura` sin explicación. El agente gastó tres objeciones peleando con una contradicción que no existía.

El agente los sufrió todos

Y varios los diagnosticó él mismo, antes que nosotros:

"Usé p-valor bajo como evidencia de anomalía de datos, pero p-valor bajo solo significa cambio estadísticamente significativo."

"¿Por qué Callao y Arequipa son anomalía y Miraflores no? La diferencia es solo de magnitud, no de naturaleza."

Esa segunda frase es la crítica correcta a un umbral mal calibrado — escrita por el agente que lo estaba sufriendo.

Cuando un agente se equivoca,

la primera sospecha no debería ser el modelo.

Casi siempre es lo que le diste de comer.

Lo que se llevan

- Un agente con arquitectura cognitiva, corriendo, con su interfaz
- El criterio para elegir la métrica correcta antes que el umbral correcto
- La diferencia entre deriva y anomalía, y por qué cuesta caro confundirlas
- Una política de acción que no depende de la buena voluntad del modelo

Todo el laboratorio queda en:

github.com/texai/taller-ia-uni-lab

```
make verificar          # 24 comprobaciones, sin gastar un token
```

Gracias

Ernesto Anaya

Taller 02 · Caso aplicado de IA en industria

UNI · Agosto 2026