



Las siete herramientas del agente

Guía 4 · Taller 02 de caso aplicado de IA en industria

Los ojos del agente. Viven en `agente/herramientas.py` y son lo único que el modelo puede mirar del mundo.

La lista

HERRAMIENTA	QUÉ DEVUELVE	CUÁNDO LA LLAMA
<code>listar_modelos</code>	El inventario: cuántos, de qué categoría y región	Primero, para saber sobre qué trabaja
<code>resumen_flota</code>	Salud de los 192: error, sesgo, cobertura y los peores	El punto de partida de cualquier diagnóstico
<code>agregado_por</code>	Las métricas agregadas por categoría, tienda o región	Para ver la forma del problema
<code>comparar_periodos</code>	Una ventana reciente contra una línea base, con test estadístico	Para decidir si algo cambió de verdad
<code>detectar_anomalias</code>	Series cortadas, tiendas mudas, huecos en los datos	Antes de culpar al modelo
<code>estado_del_job</code>	Si el job corrió, cuánto tardó, cuántas filas entregó	Un modelo puede estar sano y el job caído
<code>detalle_modelo</code>	Las métricas diarias de un modelo concreto	Cuando ya sabes cuál mirar de cerca

Las tres reglas de una herramienta de percepción

1. **Devuelve agregados, no filas.** Decenas de números, no miles. Un modelo de lenguaje no puede leer 17,472 filas — y aunque pudiera, no debe.
2. **Es de solo lectura.** En producción nadie le da escritura a un agente sobre los modelos.
3. **La estadística la hace Python, no el LLM.** El modelo razona sobre los números; no los calcula.

Y una cuarta, que se descubre usándolas: la docstring es prompt. No es documentación. Es lo único que el modelo lee para decidir cuándo llamar cada herramienta, así que se escribe como se escribe un prompt.

agregado_por revela la forma

Es la más útil para diagnosticar, y la razón es que la misma degradación se ve distinta según por dónde la cortes:

- Se concentra en una **categoría** y aparece en todas las tiendas → la causa es del producto.
- Se concentra en una **tienda** y toca todas las categorías → la causa es de esa tienda.
- Un modelo suelto degradado → es otra cosa.

Y hay una trampa que vas a ver el sábado. Con la flota **sana**, agrupando por región, los dos grupos más pequeños —ocho modelos cada uno— ocupan los dos bordes de la tabla: uno con el sesgo más alto de todos, +8.7%, y otro con el MAPE más bajo, 10.9. Lima, con 112 modelos, se queda plácidamente en el medio. Y nada está roto.

El ruido no tiene signo: tiene tamaño de muestra. Por eso un umbral único marca como rotos a los grupos chicos todos los días.

Una herramienta que falla bien

El modelo se va a inventar un identificador —guion bajo donde iba guion— y eso va a pasar sí o sí. Lo que importa no es que falle: es **qué recibe cuando falla**. Un «no existe» a secas invita a reintentar con otra variante del nombre, y ahí se van cinco llamadas.

Nuestras herramientas devuelven, junto al error, el formato esperado del identificador y una lista de candidatos parecidos. Con eso el modelo corrige a la primera.

Una herramienta que falla muda convierte una llamada equivocada en tres.

Probarlas sin agente

No hace falta un LLM para mirar lo que devuelven: la API está detrás de todas. En

`http://localhost:8000/docs` está la interfaz de Swagger, que permite lanzarlas desde el navegador y ver la respuesta cruda. Es la forma más cómoda de entender qué ve el agente antes de dejarlo razonar sobre ello.
